

Примена метода истраживања података на скупу Musk (Version 2)

Предмет овог рада је истраживање података скупа Musk (Version 2). Први део представља упознавање са самом базом, њеном структуром и подацима које садржи. Други део обухвата претпроцесирање у оквиру кога су детаљније анализирани сами атрибути и њихова својства. Трећи део подразумева селекцију карактеристика на којима ће бити примењени и саму примену алгоритама кластеровања, класификације и правила придруживања, као и анализа и поређење резултата добијених за различите алгоритме.

Musk (Version 2)

Musk (Version 2) је скуп података доступан на UCI Machine Learning Repository, репозиторијуму који садржи велики број скупова података намењених за машинско учење и анализу података. Musk (Version 2) описује 102 молекула, од којих су, од стране стручњака, 39 оцењени као мошусни (musk), а 63 као молекули који нису мошусни (non-musk). Због могућности ротације хемијских веза, молекул може заузимати више различитих просторних распоред атома, односно имати више конформација. Тако је овај скуп података добијен генерисањем свих нискоенергетских конформација ова 102 молекула, па свака инстанца представља једну конформацију, односно сваком молекулу одговара више инстанци овог скупа података.

Главна карактеристика овог скупа је то што се класа додељује на нивоу целог молекула, односно ако је бар једна конформација молекула мошусна, цео молекул се класификује као мошусни, а ако ниједна конформација молекула није мошусна, молекул неће бити мошусни. Овакав проблем назива се проблем вишеструких инстанци, односно Multiple-instance problem (MIL), где нису познате ознаке појединачних инстанци, већ су оне груписане у скупове (bags) и ознаке су на нивоу целе групације.

Пошто инстанце представљају конформације молекула, важно је нагласити да су инстанце које представљају исти молекул међусобно сличније, па самим тим и зависне, па овај скуп података не представља скуп са потпуно независним инстанцама. Ипак, у складу са захтевима курса, инстанце ће бити третиране као независне, односно рад је фокусиран на посматрање различитих конформација које се сматрају независним. Одступање од овог поступка биће посебно наглашено у раду. Такође, класа целог молекула посматраће се као да је класа сваке појединачне конформације.

Скуп података се састоји од 6598 редова и 169 колона.

Прве две колоне, `molecule_name` и `conformation_name`, идентификују о којем молекулу и којој конформацији је реч и не користе се приликом учења модела. Обе су категоријског типа.


Следећих 166 колона представљају карактеристике које описују појединачне конформације и све су целобројног типа. Колоне `f1-f162` су “атрибути растојања” дуж одговарајућих зрака (rays). Мерени су у стотим деловима Ангстрема ($1\text{\AA} = 10^{-10}\text{m}$) у односу на референтну тачку дефинисану дуж сваког зрака. Пошто је свака референтна тачка одређена на основу “консензусне мошусне” површине која се више не користи, приликом рада не треба придавати значај нултој тачки, као ни позитивним ни негативним вредностима, већ податке посматрати као да су на произвољној континуалној скали. Атрибут `f163` представља растојање атома кисеоника од унапред дефинисане тачке у тродимензионалном простору (назива се још и OXY-DIS), а атрибути `f164`, `f165` и `f166` су помераји положаја атома кисеоника дуж *x*, *y* и *z* осе у односу на ту тачку.

Променљива `class` је непрекидног типа, али по свом значењу представља бинарну категоријску променљиву, са вредностима 0 и 1. Мошусни молекули су означени са 1, а молекули који нису мошусни са 0.

Претпроцесирање


У скупу података не постоје недостајуће вредности, а провером дупликата утврђено је да нема поновљених инстанци. На основу значења атрибута није могуће дефинисати јединствен опсег дозвољених вредности на основу којег би се појединачне вредности могле недвосмислено означити као неисправне. Циљна променљива која представља класу узима само вредности 0 и 1. На основу извршених провера нису уочене неправилности у подацима, па је даља обрада настављена уз претпоставку да скуп података не садржи погрешно унете вредности.

За почетан преглед одлика атрибута коришћена је дескриптивна статистика, као и графички приказ 15 насумично изабраних атрибута, у виду хистограма и `box-plot`-ова. Направљен је узорак атрибута приликом графичког приказа због бројности карактеристика, па визуелни приказ целог скупа не би био практичан ни за преглед ни за анализу. На основу вредности статистика и хистограма, примећено је да променљиве значајно варирају у погледу својих расподела: варирају у погледу симетричности, опсега вредности, средњих вредности, као и дисперзија. Тако је максимална дисперзија 17246,70, а минимална 195,31. `Box-plot`-ови су дали детаљнији увид у разнолико присуство аутлајера: неки атрибути имају значајан борј аутлајера, док код других нису примећени.



Пошто је ово била само почетна, одокативна, анализа атрибута, како би се добио бољи увид у расподеле атрибута искоришћени су skewness и kurtosis. Skewness и kurtosis су мере облика расподеле које говоре о асиметричности (skewness) и тежини репова, односно присуству екстремних вредности (kurtosis).

Оквирне границе за skewness које могу помоћи у тумачењу: уколико је вредност skewness таква да је $-0,5 < \text{skewness} < 0,5$ расподела је приближно симетрична, за $-1 < \text{skewness} < -0,5$ или $0,5 < \text{skewness} < 1$ расподела је благо асиметрична и за $\text{skewness} < -1$ или $\text{skewness} > 1$ је високо асиметрична. На основу вредности у табели може се приметити да скоро половина атрибута има асиметричну расподелу. Позитиван skewness значи да је расподела позитивно асиметрична, односно има дужи (израженији) десни реп, а негативан skewness значи да је расподела негативно асиметрична, односно има дужи леви реп.





За тумачење kurtosis-a, референтна тачка је 0 која представља вредност у случају нормалне расподеле јер pandas умањи вредност за нормалну расподелу која износи 3. Вредности веће од 0 означавају лептокуртичне расподеле код којих су репови дебљи, односно имају више екстремних вредности од нормалне расподеле. Вредности мање од 0 означавају платикуртичне расподеле код којих су репови тањи, односно имају мање екстремних вредности од нормалне расподеле. За вредности блиске 0 каже се да је расподела мезокуртична, односно блиска је нормалној расподели по питању дебљине репова и присуству екстремних вредности. Укупно 61 атрибут има $kurtosis > 0$, а 105 атрибута има $kurtosis < 0$. Уколико се као оријентациона граница за мезокуртичност узме $abs(kurtosis) < 1$, скоро половина атрибута упада у ту вредност. Ако се фокус стави на лептокуртичне, односно расподеле са дебљим реповима, може се приметити да значајан број атрибута, њих 45, има $kurtosis > 1$ (а значајан део њих веома високе вредности), па је присутна скоро трећина атрибута са дебелим реповима.

На основу овога, потврђена је претпоставка добијена на основу прегледа дескриптивне статистике и графичког приказа узорка атрибута - атрибуту, који сви представљају мере растојања, имају разноврсне расподеле и међу њима је присутно много асиметричних расподела и расподела са тешким реповима.


$ \text{skewness} < 0.5$	94
$0.5 \leq \text{skewness} < 1$	42
$ \text{skewness} \geq 1$	30

$ \text{kurtosis} < 1$	78
$\text{kurtosis} > 1$	45
$\text{kurtosis} > 2$	32
$-2 < \text{kurtosis} < -1$	43

Занимљиво је да највећи kurtosis износи 51,14 што представља веома изражену лептокуртичност. Графички прикази овог атрибута објашњавају ову вредност. На boxplot-у се јасно виде бројни аутлајери који чине скоро шестину података (њих 1018) и који се већински налазе са десне стране што је у складу са дугачким десним репом који се може приметити на хистограму и из вредности skewness-а која износи 6,07.



Важан корак у анализи атрибута подразумева испитивање њихових међусобних корелација. Представа о корелацијама између овако великог броја атрибута најбоље се може добити уз помоћ топлотне мапе која даје графички приказ јачине корелација. Мапом доминирају слабе и умерене корелације, али су присутне у значајној мери јако и веома јако корелисане променљиве што указује на присуство мултиколинеарности и биће узето у обзир у наставку рада.



Слика 5

За анализу аутлајера коришћена је IQR метода која идентификује аутлајере на основу интерквartilног распона, тако што се аутлајери налазе изван опсега $[Q1 - 1,5 \cdot IQR, Q3 + 1,5 \cdot IQR]$. Утврђено је да 70 атрибута уопште нема аутлајере, а процентуална заступљеност аутлајера у преосталим атрибутима дата је у следећој табели.

Заступљеност аутлајера	Број колона
без	70
<1%	31
између 1% и 5%	22
између 5% и 10%	16
више од 10%	27

Може се приметити варирање у погледу броја аутлајера, али пошто нема основа за тврдњу да су неке вредности сумњиве или погрешне, различитост у погледу аутлајера биће приписана различитим расподелама атрибута које природно могу имати много аутлајера добијених IQR методом посебно код расподела које су асиметричне и имају дебљи реп.

Кластеровање

Кластеровање је прва техника примењена за анализу скупа података који се посматра. Спада у ненадгледано учење и служи за проналажење природних група и кластера у подацима на основу изабране мере сличности. На тај начин омогућава стицање нових увида у структуру података и уочавање односа и образаца који претходно нису били познати или препознати.

У циљу испитивања перформанси алгоритама, формирано је више различитих скупова података помоћу техника смањења броја или трансформације оригиналних атрибута, како би се користили за изградњу и поређење модела.


Први скуп података на који ће бити примењени алгоритми је оригинални скуп података.

Као што је примећено раније, дисперзије атрибута значајно варирају. Сви атрибути мере растојања и иако се разликују по вредностима које узимају, сви су на приближно сличним скалама па је поређење њихових значајности по варијанси смислено. Два атрибута имају значајно мање варијансе од осталих (f_{147} и f_{76} имају варијансе 460,69 и 195,31, редом, док је следећа најмања варијанса 1882,98), па су уклоњени из скупа атрибута (који је у наставку додатно редукован или трансформисан) под претпоставком да не доприносе довољно будућим моделима.

Приликом анализе атрибута, уочено је да постоје значајне корелације између њих. Висока корелација између атрибута често нарушава перформансе модела, али у неким случајевима та сличност не представља вишак информација. Много тога зависи од самог алгорита који се примењује, јер различити алгоритми различито реагују на мултиколинearност. Зато је један скуп података на коме ће бити формиран модели онај из кога су уклоњени атрибути са веома високом корелацијом (изнад 0,9). Прво су пронађени сви парови атрибута чија је корелација већа од 0,9, а онда је из сваког пара уклоњен атрибут који има мању варијансу под претпоставком да је мање информативан (у случају да се у пару налази један или оба атрибута који су раније уклоњени, прелази се на следећи пар). Дакле, уклоњени су високо корелисани атрибути само тамо где је висока корелација директно уочена у паровима. На овај начин уклоњено је још 54 атрибута и добијен је скуп који има укупно 110 колона.

Трећи скуп за примену алгоритама добијен је помоћу анализе главних компоненти (Principal Components Analysis - PCA). Ово је метода трансформације атрибута са циљем да мањи број атрибута опише већину варијансе, што значи да се заснива на претпоставки да висока информативност одговара високој варијанси. Такође, добијени атрибути су некорелисани, па неће постојати ни проблем мултиколинearности. Овом трансформацијом губи се интерпретабилност самих атрибута, али у случају Musk (Version 2) то није велики губитак у поређењу са неким другим скуповима, јер атрибути свакако нису потпуно интуитивни за тумачење. То је још један разлог зашто је изабрана ова метода.

Пре примене PCA, подаци су стандардизовани, односно сваки атрибут је трансформисан тако да има средњу вредност 0 и стандардну девијацију 1. Изабране су компоненте које објашњавају укупно 90% варијансе, па се скуп података свео на 25 PCA компоненти. Графички су приказани подаци у 2 димензије са прве две компоненте, PCA1 и PCA2, које објашњавају укупно 47,64% варијације. Није примећено раздвајање по класама, али се примећују 3 добијене групе података, што може наговестити 3 кластера. У свакој групи постоје припадници обе класе.



Графички приказ података помоћу две PCA компоненте

На овај начин, добијена су 3 скупа података на којима су у наставку примењени алгоритми: оригинални, скуп из кога су уклоњени високо корелисани атрибути и скуп добијен PCA методом (као што је већ речено, друга два скупа формирана су из скупа из кога су уклоњени атрибути са малим дисперзијама).


t-SNE

Пре примене самих алгоритама искоришћен је алат за визуелизацију података t-SNE (t-Distributed Stochastic Neighbor Embedding). То је метода визуелизације података којом се подаци из високодимензионалног простора преводе у простор мање димензије (2D или 3D). Пре свега чува локалну структуру података, али може открити и глобалну структуру у некој мери, па се помоћу ове методе стиче увид у груписање и изоловање података.


Најважнији параметар је перплексност и његов избор значајно утиче на резултат. Може се тумачити као мера ефективног броја суседа. Ниже вредности фокусирају се на локалну структуру, а више вредности фокусирају се на ширу, глобалнију структуру.

Примењен је на оригиналним подацима који су скалирани пошто алгоритам користи растојања. Испитане су вредности 10, 30, 50, 100 и 150 за параметар perplexity. Остали параметри су постављени на подразумеване вредности, осим параметра `init`, за који је коришћена вредност `random`. При вредностима 10 и 30 уочене су само локалне структуре које се боље виде за вредност 30. При вредности 50 и даље доминирају локалне групе, али се назире и глобално груписање. За perplexity 100 и 150, постају јасније издвојене три групе података. За ове две вредности додатно је испитана стабилност резултата коришћењем различитих `random_state` вредности како би се проверило да ли се три издвојене групе изнова јављају. Добијена структура остала је присутна, иако су се облик и положај група мењали. Добијене групе нису раздвојиле класе, те је представника обе класе било у свакој од добијених група. Издвајање три групе у t-SNE простору може указивати на постојање три природне групе, односно потенцијална кластера. Ипак, иако може послужити као основа за даљу анализу кластеровања, овај резултат треба пажљиво посматрати јер t-SNE пре свега чува локалну структуру података.


t-SNE за perplexity = 10




t-SNE за perplexity = 30




t-SNE za perplexity = 50



t-SNE za perplexity = 100



t-SNE za perplexity = 150



K-means++

Први алгоритам кластеровања који је коришћен је k-means++, унапређени k-means алгоритам. K-means формира k кластера, где се k унапред задаје, тако што бира представнике кластера, центроиде, а затим сваку тачку додељује најближем центроиду. Све док не буде испуњен услов заустављања, ажурирају се центроиди тако да представљају аритметичку средину тачака тог кластера, а онда се тачке поново додељују

најближим центроидима. Углавном се користи Еуклидско растојање, а циљ је минимизација суме квадрата удаљености тачака од центроида.

K-means++ представља унапређење алгоритма K-means јер почетне центроиде не бира произвољно, већ само први бира произвољно, а следећи се бирају тако што се свакој тачки додели вероватноћа на основу квадрата удаљености од најближег већ изабраног центроида. Овакав избор почетних центроида омогућава бржу конвергенцију и стабилније резултате.

Најважнији хиперпараметар је k који унапред одређује број кластера. За сваки скуп података алгоритам је покренут за вредности k од 2 до 10 и изабрана је најпогоднија вредност на основу методе лакта (Elbow method) и силуета коефицијента (Silhouette coefficient).


Метод лакта (Elbow method) користи се за одређивање оптиманог броја кластера k посматрањем како се мења WCSS у зависности од k . WCSS (Within-Cluster Sum of Squares) представља суму квадрата удаљености тачака од центроида свог кластера. Вредност k у “лакту” представља најбољи компромис између сложености модела и квалитета кластеровања.

Силуета коефицијент (Silhouette coefficient) мери колико су кластери компактни и међусобно одвојени. Узима вредности између -1 и 1, при чему негативне вредности представљају лоше груписање, а блиске један јасно и густо груписање.


Алгоритам је примењен на стандардизоване податке јер се заснива на рачунању растојања. Хиперпараметри су подешени на вредности $n_init=50$ (колико пута покреће алгоритам), $max_iter=500$ (максималан број итерација у једном покретању) и $init='k-means++'$.

На оригиналном скупу података, изабрано је $k=3$, на основу оба критеријума, односно и методе лакта и силуета коефицијента који има највећу вредност за $k=3$. Добијена су 3 кластера величине 2324, 2521 и 1753 елемената по кластеру. Силуета скор, иако је најбољи, износи 0,315. Кластери су приказани визуелно ослањајући се на трансформацију оригиналних атрибута помоћу PCA. Може се приметити да су кластери углавном компактни и изгледају раздвојено, али поједине тачке различитих кластера су међусобно блиске. Пошто постоје две класе, могли бисмо помислити да су у оквиру једне класе формирана два кластера, али на графичком приказу видимо да сва три кластера имају представнике обе класе и да раздвајање по кластерима није директно повезано са раздвајањем по класама. Ту увек треба имати у виду начин на који третирамо ознаке класа које су на нивоу молекула, које могу довести до погрешних закључака јер су неке конформације третиране као мошусне иако то нису. Ипак, немошусни који имају тачну класу су такође раздвојени.


Треба имати у виду да је графички приказ само пројекција података на две РСА компоненте, па приказ не одражава у потпуности стварне односе између тачака и кластера у вишедимензионалном простору.




Метода лакта - оригинални скуп података



Силуета коефицијенти - оригинални скуп података




Кластери - оригинални скуп података




Кластери са класама - оригинални скуп података


На скупу података из којих су уклоњени високо корелисани атрибути такође је изабрано $k=3$, на основу оба критеријума, односно и методе лакта и силуета коефицијента који има највећу вредност за $k=3$. Добијена су 3 кластера величине 2275, 2578 и 1745 елемената по кластеру. Силуета скор, иако је најбољи, износи 0,233 што је још мање него малопре. Графички приказ кластера веома подсећа на претходни случај.




Метод лакта - скуп без високо корелисаних атрибута



Силуета коефицијенти - скуп без високо корелисаних атрибута




Кластери - скуп без високо корелисаних атрибута




Кластери класе - скуп без високо корелисаних атрибута


На скупу података добијених помоћу PCA, такође је изабрано $k=3$, на основу оба критеријума, односно и методе лакта и силуета коефицијента који има највећу вредност за $k=3$. Добијена су 3 кластера величине 2324, 2521 и 1753 елемената по кластеру. Силуета скор, иако је најбољи, износи 0,358. Графички приказ кластера подсећа на претходна два случаја.




Метода лакта - PCA скуп атрибута



Силуета коефицијенти - PCA скуп атрибута



Кластери - PCA скуп атрибута



Кластери класе - PCA скуп атрибута

Adjusted Rand Index (ARI) коришћен је за поређење груписања добијених применом два различита алгорита, односно за процену сличности припадности узорака кластерима. Вредност ARI-ја креће се од -1 до 1 , при чему вредност 1 означава потпуно подударање груписања, док вредност приближно 0 указује на слагање које је приближно случајно. У овом раду коришћен је када је једнак број кластера.

Ово поређење показало је да је k-means++ на оригиналном и скупу атрибута добијеном помоћу PCA дао потпуно исте кластере. Друге две комбинације избора скупа атрибута такође показују изузетну сличност, оба пута је вредност 0,972.

Вредности силуэта коефицијента изабраних модела, по коме се модели пореде, обједињене су у табели:

	Силуэта коефицијент
Оригинални скуп	0,315
Скуп без високо корелисаних	0,233
PCA скуп	0,358

На основу наведеног можемо закључити да је k-means++ дао веома сличне поделе на кластере и да је у сва три случаја најбољи избор био 3 кластера. Иако је графички приказ одавао утисак солидне поделе на кластере, силуэта скор није био тако висок, а највиши забележен је у случају PCA скупа и износи 0,358, па дводимензионални приказ не приказује све везе између података доследно. Овај алгоритам препознаје сферне кластере што је и графички приказ успео да прикаже.

Такође, оригинални и PCA скуп атрибута дали су потпуно исту поделу на кластере, што указује на то да уклањање мултиколинearности применом PCA није променило припадност узорака кластерима. Ипак, силуэта скор је био нешто већи код PCA скупа података, што указује на већу компактност и бољу раздвојеност кластера у том простору.

Ни у једном од ова три случаја није примећена подела на кластере индукована класама.

Хијерархијско кластеровање – агломеративни приступ


Следећи алгоритам кластеровања је хијерархијско кластеровање – агломеративни приступ. Он подразумева да се тачке постепено спајају у све веће кластере, па не захтева да се унапред зада број кластера.

Помоћу овог алгоритма формира се дендрограм који визуелно приказује поступак спајања тачака и кластера у све веће кластере. Даје информацију и о томе на ком растојању су се налазили кластери када је дошло до њиховог спајања. Приказује агломеративни приступ од кластера где је сваки кластер представљао само једну тачку, преко свих спајања до формирања једног великог кластера у коме се налазе све тачке базе података. Зато може помоћи при избору оптималног броја кластера.


Формирање кластера зависи од мере растојања која се користи и linkage функције која представља начин на који се одређује растојање између два кластера. Мера растојања која је коришћена је Еуклидско растојање. Прво је примењена ward linkage функција која тежи да минимизује варијансу унутар кластера и проналази сферне кластере сличне величине. Затим је примењена average linkage функција јер представља баланс између single linkage, која може да уочи произвољне кластере, осетљива је на аутлајере и може изазвати ефекат уланчавања, и complete linkage, која може да уочи компактне, сферне кластере и мање је осетљива на аутлајере.

Пошто је циљ да се формира дендограм, два хиперпараметри су подешена да буду: `n_clusters=None`, `distance_threshold=0`. Модели се праве на стандардизованим подацима. За сваки скуп изабрана је једна linkage функција, која одговара бољем моделу.

На оригиналном скупу података за ward linkage функцију на основу дендограма и силуета скорова ($k=2$: 0,251, $k=3$: 0,315, $k=4$: 0,282, $k=5$: 0,287) изабран је $k=3$ за најоптималнији број кластера. Добијена су три кластера чији је број елемената 1755, 2346 и 2497, а силуета коефицијент је као што је споменуто 0,315. Кластери су визуелно слични као у случају претходног алгоритма.




Дендограм - оригинални скуп (ward)




Класе - оригинални скуп (ward)

На оригиналном скупу података за average linkage функцију на основу дендограма и силуета скорова ($k=2$: 0,279, $k=3$: 0,262, $k=4$: 0,248, $k=5$: 0,313) изабран је $k=5$ за најоптималнији број кластера. Дендограм није указивао на једнозначну одлуку, а пошто је силуета коефицијент био већи у односу на остале изабрано је 5 кластера. Број елемената је 2484, 2363, 3, 10 и 1738, а силуета коефицијент је као што је споменуто 0,313. Формирана су два мала кластера која на графику не показују правилност и смисао, па је због скоро исте вредности силуета коефицијента за бољи модел на оригиналном скупу проглашен модел са linkage функцијом ward.




Дендограм - оригинални скуп (average)




Класе - оригинални скуп (average)

На скупу података из којег су уклоњени високо корелисани атрибути, за ward linkage функцију на основу дендограма и силуета скорова ($k=2$: 0,167, $k=3$: 0,22, $k=4$: 0,223, $k=5$: 0,232) изабран је $k=3$ за најоптималнији број кластера због изгледа дендограма, а вредности силуета коефицијената су биле врло блиске за вредности од 3 до 5. Добијена су три кластера чији је број елемената 1912, 2498 и 2188, а силуета коефицијент је као што је споменуто 0,22. Кластери подсећају на до сада најчешћу структуру, али неке тачке су неочекивано подељене.




Дендограм - скуп без високо корелисаних атрибута (ward)




Класе - скуп без високо корелисаних атрибута (ward)

На скупу података из којег су уклоњени високо корелисани атрибути, за average linkage функцију на основу дендограма и силуета скорова ($k=2$: 0,324, $k=3$: 0,305, $k=4$: 0,212, $k=5$: 0,153) изабран је $k=2$ за најоптималнији број кластера због изгледа дендограма и вредности силуета коефицијената. Добијена су два кластера чији је број елемената 9 и 6589, а силуета коефицијент је као што је споменуто 0,324. Међутим, на основу приказа ових кластера, може се приметити да је модел у потпуности омануо и скоро све тачке спојио у један кластер, па је и за скуп података из ког су уклоњени високо корелисани атрибути као бољи модел изабран модел са ward linkage функцијом.




Дендограм - скуп без високо корелисаних атрибута (average)




Класе - скуп без високо корелисаних атрибута (average)


На скупу података добијеног путем PCA, за ward linkage функцију на основу дендограма (Слика) и силуета скорова ($k=2$: 0,283, $k=3$: 0,357, $k=4$: 0,323, $k=5$: 0,328) изабран је $k=3$ за најоптималнији број кластера због изгледа дендограма и вредности силуета коефицијената. Добијена су три кластера чији је број елемената 1755, 2346 и 2497, а силуета коефицијент је као што је споменуто 0,357. Кластери подсећају на до сада најчешћу структуру (Слика).



Дендограм - PCA скуп (ward)




Класе - PCA скуп (ward)



Дендограм - PCA скуп (average)

На скупу података добијеног путем PCA, за average linkage функцију на основу дендограма (Слика) и силуета скорова ($k=2$: 0,297, $k=3$: 0,279, $k=4$: 0,278, $k=5$: 0,354) изабран је $k=5$ за најоптималнији број кластера. Дендограм није указивао на једнозначну одлуку, а пошто је силуета коефицијент био већи у односу на остале изабрано је 5 кластера. Број елемената је 1766, 2322, 3, 10 и 2497, а силуета коефицијент је као што је споменуто 0,354. Поново су формирана два мала кластера која на графику не изгледају смислено, па је због сличног силуета скорa и графичког приказа, за бољи модел на PCA скупу проглашен модел са linkage функцијом ward.

У случају сва три скупа података ward linkage функција показала се као боља, што значи да на овом скупу података боље проналази сферне кластере. Силуета скорови изабраних модела дати су у табели испод. Највећи силуета скор поново је био за PCA скуп атрибута (0,357), али поново није превише висок. У сва три случаја су формирана 3 кластера која изгледају графички веома слично као модели претходног алгоритма. Како би се та сличност проверила упоређена су прво три модела на различитим скуповима података између себе и опет су оригинални и PCA скуп имали идентичну поделу, док комбинације са скупом из ког су избачени високо корелисани атрибути имају $ARI=0,913$. Сличност кластера између k-means++ и агломеративног кластеровања на истим скуповима података дата је у табели .



Класе - PCA скуп (average)

	Силуета коефицијент
Оригинални скуп	0,315
Скуп без високо корелисаних	0,22
PCA скуп	0,357

Сличност k-means++ и агломеративног кластеровања	
Оригинални скуп	0,987
Скуп без високо корелисаних	0,909
PCA скуп	0,987

DBSCAN


DBSCAN (Density-Based Spatial Clustering of Applications with Noise) је алгоритам кластеровања заснован на густини података. Алгоритам формира кластере тако што повезује тачке које се налазе у довољно густим областима, при чему није потребно унапред задати број кластера. Једна од предности DBSCAN алгоритма је могућност препознавања аутлајера, односно тачака које не припадају ниједном кластеру. Најважнији параметри су `eps` који одређује максимално растојање за суседство и `min_samples`, који одређује минималан број тачака потребан да би се област сматрала довољно густом.

За сваки скуп испробане су различите комбинације ових параметара (`eps` = [0.5, 1, 3, 4, 5, 6, 7, 8], `min_samples` = [5, 10, 20, 50, 100]), а пошто многе комбинације дају неупотребљиве резултате, приказани су само они који задовољавају услове: број аутлајера < 2500 и силуэта скор > 0.2 и број кластера > 1.

На оригиналном скупу података добијене су вредности:

<code>eps</code>	<code>min_samples</code>	силуэта скор	број кластера	број аутлајера
7	20	0,236	14	1622
8	20	0,235	12	460
8	50	0,332	6	1578
8	100	0,288	4	2460

За најбољу вредност хиперпараметара изабрана је комбинација `eps`=8 и `min_samples`=50.




DBSCAN - оригинални скуп

На скупу података из којих су уклоњени високо корелисани, добијене су вредности:

eps	min_samples	силуета скор	број кластера	број аутлајера
5	5	0,211	193	915
5	10	0,28	78	2465
6	20	0,208	24	1945
7	50	0,251	8	1487

За најбољу вредност хиперпараметара изабрана је комбинација eps=7 и min_samples=50.




DBSCAN - скуп без високо корелисаних атрибута

На скупу података који су добијени помоћу PCA, добијене су вредности:

eps	min_samples	силуета скор	број кластера	број аутлајера
4	5	0,304	206	1466
6	20	0,217	13	1025
6	50	0,242	6	2183
7	20	0,265	8	233
7	50	0,361	5	879
7	100	0,377	4	1611
8	50	0,252	5	309
8	100	0,311	2	669

За најбољу вредност хиперпараметара изабрана је комбинација $\text{eps}=7$ и $\text{min_samples}=50$.



DBSCAN – PCA скуп

У табели је приказан број кластера, силуэта коефицијент и број аутлајера три најбоља модела за посматране скупове.

	Број кластера	Силуэта коефицијент	Број аутлајера
Оригинални скуп	6	0,332	1578
Скуп без високо корелисаних	8	0,251	1487
PCA скуп	5	0,361	879

У сва три случаја пронађен је велики број аутлајера, формирана су 3 велика кластера и неколико мањих. Мањи кластери су сваки пут постојали у близини једног истог кластера, па иако се на графичком приказу због броја тачака и дводимензионалног приказа не виде јасно мањи кластери, можда постоји локална структура која их издваја. Ипак, најбољи силуэта скор није велики, па је и сада добијен сличан резултат. Алгоритам се најбоље показао на PCA скупу, што има смисла када се узме у обзир да се теже примењује у високодимензионалном простору. Такође, иако даје могућност за отривање неправилних кластера, на графичком приказу они нису уочени.

HDBSCAN


HDBSCAN алгоритам комбинује DBSCAN и приступ заснован на густини са принципима хијерархијског кластеровања. Може идентификовати кластере произвољног облика, величине и, што га посебно издваја, густине, а такође експлицитно идентификује аутлајере. Алгоритам сам одређује број кластера на основу стабилности кластера при различитим нивоима густине.

Осетљив је на избор хиперпараметара, посебно `min_cluster_size` и `min_samples`: `min_cluster_size` је минималан број тачака који кластер мора да има да би био препознат као кластер, а `min_samples` одређује колико суседа тачка треба да има да би се сматрала довољно густо окруженом (core point). За оптимални избор хиперпараметара комбиноване су следеће вредности: `min_cluster_size` = [20, 50, 100] и `min_samples` = [10, 25, 50], редом, јер добра пракса може бити половина вредности `min_cluster_size` за `min_samples`. Модели су направљени на стандардизованим подацима.

На оригиналном скупу података добијене су следеће вредности за дате параметре:

Хиперпараметри	Број аутлајера	Силуета коефицијент	Број кластера
<code>min_cluster_size</code> = 20 <code>min_samples</code> = 10	508	0,243	25
<code>min_cluster_size</code> = 50 <code>min_samples</code> = 25	896	0,319	7
<code>min_cluster_size</code> = 100 <code>min_samples</code> = 50	2046	0,363	3

Највећа вредност силуета скорa је 0,363, али скоро трећина података су означени као аутлајери. Са друге стране, у првом случају је пронађено чак 25 кластера и силуета скор је најмањи. Зато је изабран `min_cluster_size` = 50 и `min_samples` = 25. Број елементарних по кластерима је 78, 70, 59, 2087, 2133, 1044, 231 и има 896 аутлајера. Силуета скор је 0,319.




HDBSCAN - оригинални скуп

На скупу података из ког су уклоњени високо корелисани атрибути добијене су следеће вредности за дате параметре:

Хиперпараметри	Број аутлајера	Силуета коефицијент	Број кластера
min_cluster_size = 20 min_samples = 10	1216	0,206	29
min_cluster_size = 50 min_samples = 25	308	0,199	4
min_cluster_size = 100 min_samples = 50	3050	0,294	3

Највећа вредност силуета скорa је 0,294, али скоро половина података су означени као аутлајери. Са друге стране, у првом случају је пронађено чак 29 кластера и силуета скор је приближно једнак другом случају. Зато је изабран min_cluster_size = 50 и min_samples =

25. Број елементата по кластерима је 78, 70, 6090, 52 и има 308 аутлајера. Силуета скор је 0,199.




HDBSCAN - скуп без високо корелисаних атрибута

На PCA скупу података, добијене су следеће вредности за хиперпараметре:

Хиперпараметри	Број аутлајера	Силуета коэффициент	Број кластера
min_cluster_size = 20 min_samples = 10	941	0,239	29
min_cluster_size = 50 min_samples = 25	486	0,352	4
min_cluster_size = 100 min_samples = 50	1197	0,377	4

Иако је силуета коэффициент мало нижи, изабрани су хиперпараметри min_cluster_size = 50 и min_samples = 25 као најоптималнији због мањег броја аутлајера. Број елементата по кластерима је 2184, 164, 1449, 2315 и има 486 аутлајера. Силуета скор је 0,352.



У Табели је приказан број кластера, силуета коефицијент и број аутлајера три најбоља модела за посматране скупове.

	Број кластера	Силуета коефицијент	Број аутлајера
Оригинални скуп	7	0,319	896
Скуп без високо корелисаних	4	0,199	308
PCA скуп	4	0,352	486

У случају скупа без високо корелисаних атрибута, модел је потпуно омануо формирајући један велики кластер од скоро свих података и неколико мањих. Оригинални и PCA скуп имају сличне резултате, али боље делују резултати добијени на PCA скупу што се опет може објаснити смањењем димензионалности. Иако је HDBSCAN веома напредан алгоритам који може да идентификује најразличитије кластере који притом могу бити различитих густина, у овом случају није указао на неке посебно занимљиве резултате који доста личе на резултате DBSCAN алгоритма.

GMM (Gaussian Mixture Model)


Следећи алгоритам је GMM (Gaussian Mixture Model), који претпоставља да подаци потичу из мешавине више Гаусових расподела, при чему свака расподела представља један кластер. За сваку инстанцу одређује вероватноћу припадности свакој компоненти, а параметри расподела се итеративно процењују. За то користи ЕМ (Expectation-Maximization) алгоритам, где у Е кораку процењује вероватноће припадности сваке инстанце Гаусовим компонентама, док у М кораку, на основу тих вероватноћа, поново процењује параметре расподела. GMM даје вероватноће припадања сваком кластеру (soft clustering) и погодан је за идентификовање кластера елиптичног облика.

За сваки скуп података одабрана је најбоља вредност хиперпараметра `n_components` на основу вредности силуэта коефицијента за сваки модел који је направљен.

За оригинални скуп атрибута, добијени силуэта скорови су:

k	Силуета коефицијент
2	0,243
3	0,315
4	0,233
5	0,147
6	0,108
7	0,093
8	0,108
9	0,101
10	0,097

На основу силуэта коефицијента за оптималан број кластера изабран је `k=3`.




GMM - оригинални скуп

За скуп атрибута из кога су уклоњени високо корелисани, вредности силуэта скоро су:

k	Силуэта коефицијент
2	0,15
3	0,233
4	0,172
5	0,125
6	0,134
7	0,125
8	0,115
9	0,136
10	0,118

На основу силуэта коефицијента за оптималан број кластера изабран је $k=3$.




GMM - скуп без високо корелисаних

За PCA скуп атрибута, вредности силуета скора су:

k	Силуета коефицијент
2	0,285
3	0,356
4	0,26
5	0,265
6	0,244
7	0,224
8	0,112
9	0,113
10	0,078

На основу силуета коефицијента за оптималан број кластера изабран је $k=3$.



GMM – PCA скуп

Сва три случаја су веома слична у погледу формираних кластера. У првој табели се види та сличност. Такође, подсећају на три кластера из претходних алгоритама и то се потврђује вредностима у другој табели где су упоређени кластери добијени k-means++ и

GMM алгоритмом. Овај алгоритам је добар за проналажења елиптичких кластера, што се овде показало успешним на графичком приказу, али не толико у силуэта коефицијенту који је највећи за PCA скуп и износи 0,356.

GMM	ARI
Оригинални скуп и скуп без високо корелисаних	0,967
Оригинални скуп и PCA скуп	0,983
Скуп без високо корелисаних и PCA скуп	0,95

k-means++ и GMM	ARI
Оригинални скуп	0,998
Скуп без високо корелисаних	0,993
PCA скуп	0,981

GMM	Силуэта коефицијент
Оригинални скуп	0,315
Скуп без високо корелисаних	0,233
PCA скуп	0,356

Закључци

На основу свих алгоритама добијени су релативно слични закључци. Алгоритми који добро уочавају сферне и елиптичне кластере, попут k-means++, GMM и агломеративног хијерархијског кластеровања за linkage функцију ward, уочили су 3 кластера који су у дводимензионалном приказу релативно добро раздвојени, а силуэта коефицијент показује умерено раздвајање кластера у вишедимензионалном простору. Боља раздвојеност на дводимензионалном приказу може да завара јер се подаци приказују само у две димензије. Ипак, с обзиром на високу димензионалност, силуэта скор има солидну вредност. Два алгоритма заснована на густини, DBSCAN и HDBSCAN, нису дала потенцијално занимљиве резултате који би могли указати на другачију зависност између података, па њихова способност да откривају неправилне кластере овде није дошла до изражаја. На основу свега наведеног, може се закључити да је уошена природна подела података на 3 кластера који су приближно сферног облика. Уколико се посматрају алгоритми кроз

различите скупове података, може се закључити да је скуп на коме су уклоњени високо корелисани атрибути увек давао за нијансу слабије резултате од оригиналног и PCA скупа, док су споменута два давала веома сличне резултате, PCA за нијансу боље.

Класификација

Следећа метода која је примењена јесте класификација. То је метода надгледаног учења и захтева поделу на тренинг и тест скуп. Скупови података добијени селекцијом и трансформацијом атрибута пре почетка примене алгоритама кластеровања овде не би требало да се директно користе јер су добијени на основу целог скупа података, а тест скуп не сме ни у ком облику да буде укључен у процес тренирања, јер би то представљало цурење података (data leakage).

Приликом поделе на тренинг и тест скуп, сада је укључена информација о томе ком молекулу која конформација припада, односно подела је извршена тако да све конформације једног молекула буду или у тренинг или у тест скупу. Разлог за то је што, као што је раније речено, различите конформације истог молекула нису потпуно независне. Овако се спречава цурење података, јер би се у супротном различите конформације истог молекула могле наћи у оба скупа. То би довело до тога да тест скуп није потпуно независан од тренинг скупа и могло би вештачки повећати перформансе модела.

Молекули су распоређени у тренинг и тест скуп тако да 0,7 података буде у тренинг скупу, а 0,3 података у тест скупу, уз очување односа класа. Подела је извршена тако да се молекули поделе у односу 0,7/0,3, али однос је успео да се пренесе и на конформације (пошто немају сви молекули исти број конформација, потенцијално би могао бити нарушен). Приликом поделе, очуван је однос класа на тренинг скупу, док је на тест скупу мало измењен (цео скуп: 0,85/0,15, тренинг скуп: 0,89/0,11, тест скуп: 0,75/0,25).

Сада је могуће применити исти поступак за добијање скупа података из којих су уклоњени високо корелисани атрибути, као и примена PCA, али сада је тај поступак примењен на тренинг скупу. Свака од наредних метода примењена је на тренинг скупу из ког су уклоњена 2 атрибута са најмањом дисперзијом (као и раније).


Скуп података добијен уклањањем високо корелисаних сада се састоји од 106 атрибута, јер је уклоњено још 58 атрибута.

Скуп података добијен применом PCA методе на тренинг скупу тако да објашњава 90% варијансе има 24 колоне.

Пошто је класификација техника надгледаног учења и познате су класе, за формирање скупа атрибута изабране су још две методе - помоћу ANOVA теста и LDA трансформације.

Као још један вид селекције атрибута, коришћен је ANOVA тест (анализа варијансе). ANOVA се користи за рангирање атрибута на основу F-статистике, која представља однос варијансе између класа и варијансе унутар класа. Веће F-скор вредности указују на то да се средње вредности посматраног атрибута више разликују између класа у односу на варијабилност унутар самих класа. Због тога се атрибути са већим F-скором сматрају информативнијим за разликовање молекула са мирисом мошуса и молекула без мириса мошуса, па се могу користити за селекцију најзначајнијих атрибута и смањење димензионалности података. Изабрано је 50 атрибута са највећом F-скором.

Искоришћена је још једна метода смањења димензионалности, LDA (Linear Discriminant Analysis). LDA трансформише податке у дискриминантни потпростор чија максимална димензија износи $k-1$, где је k број класа. Циљ је да се максимизује варијанса између класа и минимизује варијанса унутар класа. Пошто наша база података садржи само две класе, максимална димензија LDA простора износи један (Слика). Ово омогућава занимљиву анализу колико успешна класификација може бити када податке представимо помоћу само једне дискриминантне компоненте.



У наставку рада примењују се алгоритми класификације. Пре почетка битно је нагласити да се, у складу са захтевима курса, примењују класични, а не MIL алгоритми, те се претпоставља да свака коформација има класу која је додељена целом молекулу. Очекивано је да ова претпоставка наруши квалитет модела, јер не носи потпуно тачну информацију, односно неке немошусне коформације биће третиране као мошусне.

Decision Tree

Први алгоритам је Decision Tree. То је један од најинтуитивнијих алгоритама јер се заснива на формирању стабла одлучивања које чине унутрашњи чворови и листови. Унутрашњи чворови садрже услов над одређеним атрибутом, на основу којег се врши даља подела узорака, док су листови крајњи чворови који се више не деле. Сваком листу додељује се једна класа.


За сваки чвор рачуна се његова нечистоћа помоћу изабраног критеријума, а бира се она подела чвора која обезбеђује највеће смањење нечистоће. Код коришћеног DecisionTreeClassifier-а поделе су бинарне, односно сваки чвор се дели на два потомка. На овај начин формирано стабло одлучивања своди се на низ провера услова које се примењују све док се не дође до листа, на основу којег се узорку додељује класа.

Помоћу унакрсне валидације, за сваки скуп података испробане су различите комбинације хиперпараметара `max_depth` и `min_samples_leaf` и изабрана је она која даје најквалитетнији модел на основу `f1` скорa. Хиперпараметар `max_depth` представља максималну дубину стабла, док `min_samples_leaf` представља минималан број узорака који мора да се налази у листу.

Како би се изабрала најбоља вредност хиперпараметара, коришћена је унакрсна валидација. При томе, из истог разлога као приликом поделе на тренинг и тест скуп, фолдови су направљени тако да све конформације једног молекула буду у једном фолду. Такође, покушава да задржи однос класа у фолдовима.


У наставку су приказане мере квалитета на оригиналном скупу (`max_depth=10`, `min_samples_leaf=20`).

accuracy	f1	precision	recall	auc
0,403	0,143	0,111	0,2	0,344




У наставку су приказане мере квалитета на скупу из ког су уклоњени високо корелисани атрибути ($\text{max_depth}=7$, $\text{min_samples_leaf}=5$).

accuracy	f1	precision	recall	auc
0,459	0,158	0,128	0,205	0,359




У наставку су приказане мере квалитета на скупу добијеном помоћу PCA (max_depth=7, min_samples_leaf=5).

accuracy	f1	precision	recall	auc
0,612	0,302	0,272	0,339	0,515




У наставку су приказане мере квалитета на скупу добијеном помоћу ANOVA (max_depth=7, min_samples_leaf=20).

accuracy	f1	precision	recall	auc
0,564	0,187	0,174	0,202	0,401



У наставку су приказане мере квалитета на скупу добијеном помоћу LDA (max_depth=None, min_samples_leaf=7).

accuracy	f1	precision	recall	auc
0,571	0,398	0,305	0,572	0,614



Decision Tree се уопште није показао добро. На оригиналном и скупу са уклоњеним високо корелисаним атрибутима, резултати су гори од насумичних, на PCA и ANOVA скупу резултати су нешто бољи, али ни близу квалитетних, па су ближи насумичним, али f1 score, precision и recall су веома мали. Интересантно је да је најбоље резултате дао LDA, па auc износи 0,614 што је мало боље од вредности auc-а за насумичну класификацију. Ипак f1 скор је и даље низак.

Bagging Decision Tree

Decision Tree има тенденцију да направи нестабилан модел који се значајно мења уколико се промене подаци на којима се тренира, односно има велику варијансу, посебно када је max_depth=None. Зато желимо стабилнији модел, што се може постићи применом bagging методе.


Bagging је ансамбл метода која тренира више истих базних модела независно, при чему се сваки модел тренира на различитом bootstrap узорку тренинг скупа, односно узорку добијеном случајним бирањем са враћањем. На тај начин добијамо више различитих модела, чије се предикције на крају комбинују. Код класификације се коначна класа одређује већинским гласањем предикција појединачних модела.

Пошто је базни модел Decision Tree, estimator=DecisionTreeClassifier() са раније добијеним оптималним хиперпараметрима за сваки од скупова на којим се модел прави. Остала

подешавања која нису подразумевана су $n_estimators=100$, $max_samples=0.7$ и $oob_score=True$.


У наставку су приказане мере квалитета на оригиналном скупу:

accuracy	f1	precision	recall	auc
0,47	0,185	0,149	0,242	0,269




У наставку су приказане мере квалитета на скупу из кога су уклоњени високо корелисани атрибути:

accuracy	f1	precision	recall	auc
0,472	0,178	0,145	0,231	0,274




У наставку су приказане мере квалитета на скупу добијеном помоћу PCA:

accuracy	f1	precision	recall	auc
0,608	0,3	0,269	0,339	0,551



У наставку су приказане мере квалитета на скупу добијеном помоћу ANOVA:


accuracy	f1	precision	recall	auc
0,662	0,245	0,274	0,221	0,317



У наставку су приказане мере квалитета на скупу добијеном помоћу LDA:

accuracy	f1	precision	recall	auc
----------	----	-----------	--------	-----

0,6	0,418	0,325	0,57	0,635
-----	-------	-------	------	-------



Није примећено побољшање у погледу квалитета модела, једино је модел на LDA скупу показао незнатно побољшање којим се може сматрати барем мало бољим од насумичног, али ништа више од тога.


Random Forest

Следећи примењени алгоритам је Random Forest, који спада у ансамбл методе јер комбинује већи број стабала одлучивања. Комбиновањем предикција више стабала добија се стабилнији модел, са мањом склоношћу ка преприлагођавању у односу на појединачно стабло одлучивања. Свако стабло се обучава на bootstrap узорку скупа за тренирање, а при свакој подели стабла разматра се само случајно одабран подскуп обележја.

Помоћу унакрсне валидације, за сваки скуп података испробане су различите комбинације хиперпараметара `max_depth` и `min_samples_leaf` и изабрана је она која даје најквалитетнији модел на основу `f1` скорa. Хиперпараметар `max_depth` представља максималну дубину стабла, док `min_samples_leaf` представља минималан број узорака који мора да се налази у листу.


У наставку су приказани резултати добијени на оригиналном скупу (`max_depth=20`, `min_samples_leaf=4`).

accuracy	f1	precision	recall	auc
0,449	0,166	0,133	0,221	0,304




У наставку су приказани резултати добијени на скупу из којих су уклоњени високо корелисани атрибути ($\text{max_depth}=20$, $\text{min_samples_leaf}=2$).

accuracy	f1	precision	recall	auc
0,495	0,177	0,149	0,22	0,281




У наставку су приказани резултати на скупу добијеном помоћу PCA (max_depth=20, min_samples_leaf=2).

accuracy	f1	precision	recall	auc
0,698	0,284	0,343	0,242	0,554




У наставку су приказани резултати на скупу добијеном помоћу ANOVA (max_depth=10, min_samples_leaf=6).

accuracy	f1	precision	recall	auc
0,612	0,219	0,218	0,22	0,53



У наставку су приказани резултати на скупу добијеном помоћу LDA (max_depth=10, min_samples_leaf=6).

accuracy	f1	precision	recall	auc
0,59	0,415	0,321	0,589	0,634



Поново, ни Random Forest није успео да ухвати структуру и модели се уопште нису поправили.


KNN (K-Nearest Neighbors)

KNN (K-Nearest Neighbors) је један од најједноставнијих алгоритама класификације. Класа новог узорка одређује се на основу класа његових k најближих суседа из скупа за тренирање, тако што се новом узорку додељује најзаступљенија класа његових k суседа. Близина суседа одређује се на основу изабране метрике удаљености. Оно што је карактеристично за овај алгоритам јесте то што не формира експлицитни модел на основу тренинг скупа, већ током предвиђања рачуна удаљености између новог узорка и тренинг узорака и на основу њих проналази најближе суседе. Због тога се KNN сврстава у instance-based, односно lazy learning методе.

Алгоритам се примењује на стандардизованим подацима. За сваки скуп података је на почетку помоћу унакрсне валидације одређена најбоља комбинација хиперпараметара n_neighbors (број најближих суседа који се посматрају), weights (колико и како суседи допринос) и metric (метрика која се користи приликом рачунања удаљености између узорака). Испробаване су вредности: n_neighbors = [5, 15, 21, 31, 41, 51], weights = [uniform, distance], metric = [euclidean, manhattan].


У наставку су приказани резултати на оригиналном скупу (metric='euclidean', n_neighbors=5, weights='uniform').

accuracy	f1	precision	recall	auc
0,535	0,418	0,303	0,676	0,617




У наставку су приказани резултати на скупу из кога су уклоњени високо корелисани атрибути (metric='manhattan', n_neighbors=5, weights='distance').

accuracy	f1	precision	recall	auc
0,725	0,545	0,462	0,665	0,689




У наставку су приказани резултати на скупу добијеном помоћу PCA (metric='manhattan', n_neighbors=5, weights='uniform').

accuracy	f1	precision	recall	auc
0,568	0,436	0,323	0,674	0,608




У наставку су приказани резултати на скупу добијеном помоћу ANOVA (metric='euclidean', n_neighbors=5, weights='distance').

accuracy	f1	precision	recall	auc
0,677	0,465	0,394	0,566	0,665



У наставку су приказани резултати на скупу добијеном помоћу LDA (metric='euclidean', n_neighbors=5, weights='uniform').

accuracy	f1	precision	recall	auc
0,59	0,411	0,319	0,576	0,612



Примећено је побољшање у односу на претходне алгоритме. Сада се сви могу сматрати мало бољим од насумичних, а најбоље перформансе овога пута показао је модел трениран на скупу атрибута из који су уклоњени високо корелисани. Његова генерална способност да раздваја класе, односно аус, износи 0,689. Такође, по први пут recall има вредност 0,665. Recall означава способност модела да идентификује инстанце које су у стварности означене као мошусне. Такође, тачност је сада 0,725.

XGBoost


XGBoost припада групи boosting алгоритма. Boosting алгоритми представљају ансамбл методе које конструишу више модела секвенцијално, при чему сваки наредни модел настоји да исправи грешке претходно изграђених модела. XGBoost представља унапређену и оптимизовану имплементацију Gradient Boosting алгоритма. Док Gradient

Boosting користи градијент функције губитка за усмеравање изградње наредног модела, XGBoost, поред првог извода, користи и други извод функције губитка (Хесијан) за прецизнију оптимизацију. Такође, XGBoost укључује напредне технике регуларизације које помажу у смањењу преприлагођавања, као и оптимизације које омогућавају ефикасну обраду великих скупова података.

За сваки скуп података је на почетку помоћу унакрсне валидације одређена најбоља комбинација хиперпараметара `n_estimators` (број стабала односно итерација boosting-a), `max_depth` (максимална дубина сваког стабла), `learning_rate` (колики допринос свако ново стабло има у коначном моделу).


У наставку су приказани резултати на оригиналном скупу (`n_estimators=200`, `max_depth=7`, `learning_rate=0.1`).

accuracy	f1	precision	recall	auc
0,69	0,393	0,381	0,405	0,537




У наставку су приказани резултати на скупу из кога су уклоњени високо корелисани атрибути (`n_estimators=200`, `max_depth=7`, `learning_rate=0.1`).

accuracy	f1	precision	recall	auc
0,702	0,358	0,384	0,335	0,553




У наставку су приказани резултати на скупу добијеном помоћу PCA ($n_estimators=200$, $max_depth=7$, $learning_rate=0.1$, $random_state=42$).

accuracy	f1	precision	recall	auc
0,767	0,486	0,535	0,446	0,702




У наставку су приказани резултати на скупу добијеном помоћу ANOVA ($n_estimators=100$, $max_depth=3$, $learning_rate=0.1$, $random_state=42$).

accuracy	f1	precision	recall	auc
0,71	0,293	0,37	0,242	0,674



У наставку су приказани резултати на скупу добијеном помоћу LDA ($n_estimators=200$, $max_depth=5$, $learning_rate=0.1$, $random_state=42$).

accuracy	f1	precision	recall	auc
0,628	0,43	0,346	0,566	0,647



Овога пута, најбоље резултате дао је модел на PCA скупу, па тако сада има auc 0,702, тачност 0,767 и f1 скор 0,486. Остали модели нису показали значајнији резултат у односу на kNN моделе.


SVM

Још један алгоритам који се може користити за класификацију је Support Vector Machine (SVM). Основна идеја SVM алгоритма јесте проналажење оптималне хиперравни која раздваја податке различитих класа тако да се максимизује маргина, односно растојање између хиперравни и најближих података из обе класе, уз минимизовање грешака класификације. Ти најближи подаци називају се вектори подршке (support vectors) и имају кључну улогу у одређивању положаја оптималне границе одлучивања (decision boundary). SVM може ефикасно да ради и са нелинеарно раздвојивим подацима коришћењем kernel функција, које омогућавају пресликавање података у простор веће димензионалности. Његова значајна предност је ефикасност у раду са високодимензионалним просторима.

Алгоритми се примењују на стандардизованим подацима. За сваки скуп података је на почетку помоћу унакрсне валидације одређена најбоља комбинација хиперпараметара kernel (kernel функција која се користи) и C (компромис између ширине маргине и грешке класификације). Додатно, за RBF кернел, подешава се хиперпараметар gamma (колики далеко досеже утицај једног узорка).

У наставку су приказани резултати на оригиналном скупу података (C=10, gamma=0.01, kernel='rbf').


accuracy	f1	precision	recall	auc
0,633	0,474	0,367	0,667	0,715



У наставку су приказани резултати на скупу из кога су уклоњени високо корелисани атрибути (C=1, gamma=0.01, kernel='rbf').


accuracy	f1	precision	recall	auc
----------	----	-----------	--------	-----

0,575	0,442	0,328	0,68	0,679
-------	-------	-------	------	-------




У наставку су приказани резултати на скупу добијеном помоћу PCA ($C=1$, $\text{gamma}=0.01$, $\text{kernel}=\text{'rbf'}$).

accuracy	f1	precision	recall	auc
0,585	0,434	0,328	0,643	0,654




У наставку су приказани резултати на скупу добијеном помоћу ANOVA ($C=1$, $\text{gamma}=\text{'scale'}$, $\text{kernel}=\text{'rbf'}$).

accuracy	f1	precision	recall	auc
0,72	0,482	0,444	0,527	0,737



У наставку су приказани резултати на скупу добијеном помоћу LDA ($C=1$, $\gamma=0.01$, $\text{kernel}='rbf'$).

accuracy	f1	precision	recall	auc
0,629	0,428	0,347	0,56	0,659



Овога пута, најбољи резултати уочени су за моделе настале на оригиналном и ANOVA скупу, али то су и даље сличне перформансе као код ранијих најбољих модела.

Уколико се посматра све заједно, Decision Tree, Bagging Decision Tree и Random Forest нису успели апсолутно ништа да науче из података, осим у случају LDA скупа када су сва три пута добијени модели са сличним мерама квалитета. На основу аус-а показују способност мало већу од насумичне са вредностима мало већим од 0,6, али f скор је и даље низак са вредностима око 0,4.

У случају, остала три алгоритама, резултати су били мало бољи у односу на прва три генерално гледано. Сваки пут је модел на неком другом скупу показао најбоље перформансе, а остали су углавном били на нивоу модела на LDA скупу у прва три случаја. Ипак и најбољи модели показују слабе перформансе, па се може закључити да класични алгоритми на MIL проблему нису успели да дају значајне резултате.

Правила придруживања

Правила придруживања спадају у методе ненадгледаног учења и користе се за проналажење образаца и правилности које се често појављују у подацима. Атрибути базе Musk (Version 2), као што је већ наведено, представљају различите удаљености у конфигурацијама молекула. Самим тим, њихова интерпретација није једноставна, што примену правила придруживања на оваквим подацима чини захтевнијом. Такође, сви атрибути су нумерички, па је пре примене алгоритама потребно извршити дискретизацију.

У алгоритме би се могла укључити и колона која представља класу, како би се учила правила која повезују одређене атрибуте са класом. Међутим, пошто је скуп података MIL проблем, класа у наредним алгоритмима неће бити укључена, јер би њено коришћење могло довести до погрешне интерпретације пронађених правила.

Поступак претварања нумеричких атрибута у категоријске, односно дискретизација, који је примењен у овом раду јесте подела на интервале једнаке фреквенције. Код ове методе интервали садрже приближно једнак број инстанци. Овај поступак је изабран из неколико разлога. Пре свега, представља погодан приступ за дискретизацију нумеричких атрибута у контексту правила придруживања, јер смањује могућност формирања веома ретких интервала који се могу јавити приликом поделе на интервале једнаке ширине. Такви интервали могу довести до појаве малог броја инстанци појединих категорија, чиме се може смањити ефикасност проналажења честих образаца. Приликом претпроцесирања уочено је да расподеле атрибута често нису симетричне и да се код великог броја њих појављују екстремне вредности, што управо говори о могућности настанка наведеног проблема ако би се дискретизација вршила путем интервала једнаке ширине. Коначно, атрибути базе узимају вредности на континуираној скали, без јасно дефинисаних природних граница које би омогућиле њихову смислену поделу на категорије. Због тога ни ручно дефинисање интервала на основу унапред изабраних вредности не би представљало оправдан приступ.

Алгоритми правила придруживања биће примењени на оригиналном скупу и скупу из кога су уклоњени високо корелисани атрибути да би се упоредили перформансе. Сада неће бити коришћен скуп добијен помоћу PCA јер атрибути нису интерпретабилни.

Apriori алгоритам


Први алгоритам који је коришћен је Apriori алгоритам. Apriori алгоритам представља један од основних алгоритама за откривање честих образаца и правила придруживања. Његова

основна идеја заснива се на својству затворења на ниже,односно ако је неки скуп ставки чест, онда су и сви његови подскупови такође чести. На основу тог својства алгоритам постепено формира скупове ставки све веће величине и задржава само оне који задовољавају задати праг подршке (support). Apriori алгоритам је примењен над дискретизованим атрибутима базе MUSK 2, након њиховог претварања у трансакције и претварања у DataFrame који је у облику one-hot encoding-a.

Због проблема са извршавањем за low_memory=False коришћен је low_memory=True. Такође, max_len је подешен на 3, а за min_support су испробане вредности 0,05, 0,1, 0,2 и 0,3, али због превеликог броја честих скупова за прве три вредности, коришћен је min_support=0,3. Добијено је 1619 честих скупова, а време извршавања је 4,423 секунде. Након испитивања различитих вредности min_conf, изабрана је вредност 0,95, јер ниже вредности резултују веома великим бројем пронађених правила, што отежава њихову даљу анализу. За min_conf=0,95 добијено је 2248 правила. Правила су сортирана на основу lift-a, а чак 2210 правила има вредност lift-a већу од 2.


Закључак је да су пронађена бројна правила максималне дужине 3 која имају високу поузданост (confidence), односно условну вероватноћу да ће се наћи глава правила ако је присутно тело правила. Такође, скоро сва правила имају lift већи од 2, а сви имају lift већи од 1. Lift процењује снагу правила у односу на случајност.

Приликом тумачења ових правила мора се узети у обзир да су атрибути корелисани и да више конформација потиче од истог молекула, па се одређено правило може јављати чешће уколико тај молекул има велики број инстанци. Ови фактори могу довести до повећања броја пронађених правила, као и до високих вредности њихових мера квалитета, попут confidence и lift. Као додатни фактор може се навести дискретизација помоћу интервала једнаке фреквенције, која обезбеђује приближно уједначену учесталост категорија и тиме омогућава да већи број комбинација буде довољно чест за издвајање.



Двадесет правила придруживања са највећим лифтом дато је у наставку.


Mrežni prikaz top 20 pravila sa najvećim Liftom



У наставку је коришћен исти праг за support и confidence како би се упоредили резултати.


Apriori algoritam je uz iste parametre primeњen i na skupu добијеном уклањањем високо корелисаних атрибута. Добијено је 412 честих скупова, а време извршавања је 1,025 секунди. За $\text{min_conf}=0,95$ добијено је 45 правила. Правила су сортирана на основу lift-a, а сада је само 8 правила имало вредност lift-a већу од 2, али су сви имали вредност lift-a већу од 1.

У поређењу са оригиналним скупом, након уклањања високо корелисаних атрибута добијен је значајно мањи број честих скупова и правила. Ово се може објаснити смањењем броја атрибута и уклањањем међусобно снажно повезаних атрибута, чиме је смањен број могућих комбинација које алгоритам може да издвоји. Иако је број правила смањен, сва издвојена правила имају lift већи од 1. Међутим, само 8 правила има lift већи од 2, што указује да је број правила са изражено јаким повезаношћу значајно мањи него код оригиналног скупа.



Двадесет правила придруживања са највећим лифтом дато је у наставку.

Mrežni prikaz top 20 pravila sa najvećim Liftom



Наредна два алгоритма дају исте резултате на два посматрана скупа, али разликују се по имплементацији, брзини и ефикасности.

FP-Growth

FP-Growth (Frequent Pattern Growth) је следећи алгоритам правила придруживања, односно проналажења честих скупова ставки. За разлику од Apriori алгоритма, FP-Growth не генерише велики број кандидата, већ користи FP-стабло (Frequent Pattern Tree) за компактно представљање података и ефикасније проналажење честих образаца.

Време извршавања овог алгоритма на оригиналном скупу података је 65,738 секунди.

Време извршавања овог алгоритма на скупу података из кога су уклоњени високо корелисани атрибути је 28,991 секунди.

H-Mine

H-Mine представља ефикасан приступ за откривање честих скупова елемената у великим скуповима података, који се затим могу користити за формирање правила придруживања. Његова главна предност је ефикасно коришћење меморије и структура података које омогућавају бржу претрагу великих скупова података. H-Mine не захтева генерисање великог броја кандидата, што може значајно смањити време извршавања.

Време извршавања овог алгоритма на оригиналном скупу података је 3,465 секунди.

Време извршавања овог алгоритма на скупу података из кога су уклоњени високо корелисани атрибути је 1,086 секунди.

Као најмање ефикасан од ова три алгоритма показао се FP-Growth, док су друга два била слична по ефикасности, H-Mine је мало ефикаснији.

ECLAT алгоритам

ECLAT је алгоритам за проналажење честих скупова елемената у трансакционим базама података. За разлику од Apriori алгоритма, који користи хоризонталну организацију података, ECLAT користи вертикалну репрезентацију, где се за сваки елемент чува листа трансакција у којима се он појављује. Комбинацијом и пресеком ових листа алгоритам ефикасно израчунава подршку за различите скупове елемената.

Покушана је имплементација алгоритма ECLAT, али овај алгоритам није успео да пронађе резултате јер је $\min_support$ био постављен на 0,3. Пошто је подршка свих једночланих скупова била око 0,33, алгоритам је након тога покушао да пронађе већи број комбинација. Ипак, сада је због великог броја ставки добијених дискретизацијом 166 атрибута, број комбинација екстремно повећао трајање извршавања алгоритма, а након тога би било потребно правити и трочлане комбинације. Због тога је извршавање постало потпуно неефикасно.

FP-Max

FP-Max је алгоритам намењен за проналажење максималних честих скупова ставки у базама података. Максималан чест скуп ставки је чест скуп ставки чији ниједан надскуп није чест. Максималне репрезентације су са губитком информација у погледу support-a,

али без губитка информација у погледу припадности скупова ставки. На тај начин се смањује број резултата и омогућава ефикаснија анализа великих количина података. Алгоритам се заснива на FP-Tree структури, која омогућава компактно представљање података и брже проналажење максималних честих скупова.

Време извршавања овог алгоритма на оригиналном скупу података је 66,198 секунди. Пронађена су 594 максимална скупа ставки са највише три члана.

Време извршавања овог алгоритма на скупу података из кога су уклоњени високо корелисани атрибути је 27,266 секунди. Пронађено је 320 максималних скупова ставки са највише три члана.